RAPPORT DE STAGE :

Estimation du State of Charge d'une Batterie Lithium-ion par les Méthodes EKF et LSTM

Présenté par : Deghal Anis
Sous la direction de : Bassem Sellami

Démarche et Outils :

Ce projet de stage adopte une démarche comparative rigoureuse entre les méthodes d'estimation basées sur des modèles physiques et celles issues de l'apprentissage profond. L'objectif est d'évaluer la précision et la robustesse du Filtre de Kalman Étendu (EKF) face à un réseau de neurones récurrents de type LSTM. Pour mener à bien cette étude, l'environnement de calcul technique MATLAB a été utilisé comme outil principal pour la simulation du comportement électrochimique de la batterie, le traitement des données et l'implémentation des algorithmes d'estimation.

Année Universitaire 2025 - 2026

Table des Matières

1. Introduction Générale
2. Chapitre 1 : Étude Bibliographique et Théorique
    - 2.1. Les Batteries Lithium-ion
        - 2.1.1. Principe de fonctionnement et Chimie
        - 2.1.2. Mécanismes de Dégradation
    - 2.2. Le Système de Gestion de Batterie (BMS)
    - 2.3. L'État de Charge (SoC) et les défis de son estimation
3. Chapitre 2 : Modélisation de la Batterie
    - 3.1. Modèles Électriques Équivalents (ECM)
    - 3.2. Équations d'état du modèle d'ordre 2
4. Chapitre 3 : Algorithmes d'Estimation
    - 4.1. Filtre de Kalman Étendu (EKF)
    - 4.2. Réseaux de Neurones LSTM
5. Chapitre 4 : Résultats et Comparaison
    - 5.1. Simulation du Comportement de la Batterie
    - 5.2. Résultats de l'Estimation
        - 5.2.1. Estimation par EKF
        - 5.2.2. Estimation par LSTM
    - 5.3. Comparaison Globale et Analyse des Erreurs
    - 5.4. Synthèse Comparative
6. Conclusion Générale
7. Références

1. Introduction Générale

L'ère contemporaine est marquée par une demande énergétique croissante et une prise de Conscience accrue des impératifs environnementaux. Dans ce contexte, les technologies de stockage d'énergie jouent un rôle pivot, et parmi elles, les batteries Lithium-ion (Li-ion) se sont imposées comme la solution prédominante. Leur adoption massive s'étend des véhicules électriques aux systèmes de stockage d'énergie renouvelable à grande échelle, en passant par une multitude d'équipements électroniques portables. Cette prééminence est justifiée par leurs caractéristiques intrinsèques avantageuses : une densité énergétique élevée, un faible taux d'autodécharge et une longue durée de vie, des attributs essentiels pour répondre aux exigences des applications modernes [1].

Cependant, la gestion des batteries Li-ion représente un défi technologique significatif. Ces systèmes électrochimiques sont intrinsèquement complexes, non-linéaires et particulièrement sensibles aux conditions de fonctionnement. Une utilisation en dehors des plages de sécurité spécifiées (telles que des températures extrêmes, des surcharges ou des décharges profondes) peut non seulement accélérer leur dégradation et entraîner une perte de capacité irréversible, mais aussi présenter des risques critiques, notamment l'emballement thermique. Pour atténuer ces risques, optimiser les performances et prolonger la durée de vie opérationnelle de ces batteries, l'intégration d'un Système de Gestion de Batterie (BMS – Battery Management System) est impérative.

Au sein des multiples fonctions du BMS, l'estimation précise de l'État de Charge (SoC – State of Charge) se révèle être l'une des plus cruciales et des plus complexes. Le SoC est l'équivalent numérique de la jauge de carburant d'un véhicule, indiquant la quantité d'énergie résiduelle disponible par rapport à la capacité maximale actuelle de la batterie [2]. La difficulté majeure de cette estimation réside dans le fait que le SoC est une variable d'état interne non directement mesurable par des capteurs physiques. Sa détermination est compliquée par la non-linéarité de la relation tension-SoC, les phénomènes d'hystérésis, et la présence de bruit et de dérive dans les mesures des capteurs, qui peuvent s'accumuler au fil du temps.

Le présent projet de stage a pour objectif d'explorer, d'implémenter et de comparer deux méthodologies distinctes pour l'estimation du SoC, chacune représentant une approche fondamentale dans le domaine :

• Le Filtre de Kalman Étendu (EKF) : Une approche classique, basée sur un modèle physique de la batterie, qui utilise des principes de filtrage pour estimer l'état interne.

• Le réseau de neurones récurrents de type LSTM (Long Short-Term Memory) : Une approche moderne, axée sur les données (Data-Driven), qui exploite les capacités de l'apprentissage profond pour modéliser les dynamiques complexes de la batterie.

Ce rapport est structuré en plusieurs chapitres. Le Chapitre 2 propose une étude bibliographique et théorique approfondie des batteries Lithium-ion, de leur fonctionnement, de leurs mécanismes de dégradation et du rôle du BMS, ainsi qu'une discussion détaillée sur les défis de l'estimation du SoC. Le Chapitre 3 est dédié à la modélisation de la batterie, en se concentrant sur les Modèles Électriques Équivalents (ECM) et les équations d'état du modèle d'ordre 2. Le Chapitre 4 présente les algorithmes d'estimation, EKF et LSTM, en détaillant leurs principes de fonctionnement. Enfin, le Chapitre 5 expose les résultats des simulations, une analyse comparative des performances des deux méthodes, et une discussion approfondie de leurs avantages et inconvénients, avant de conclure sur les perspectives futures.

2. Chapitre 1 : Étude Bibliographique et Théorique

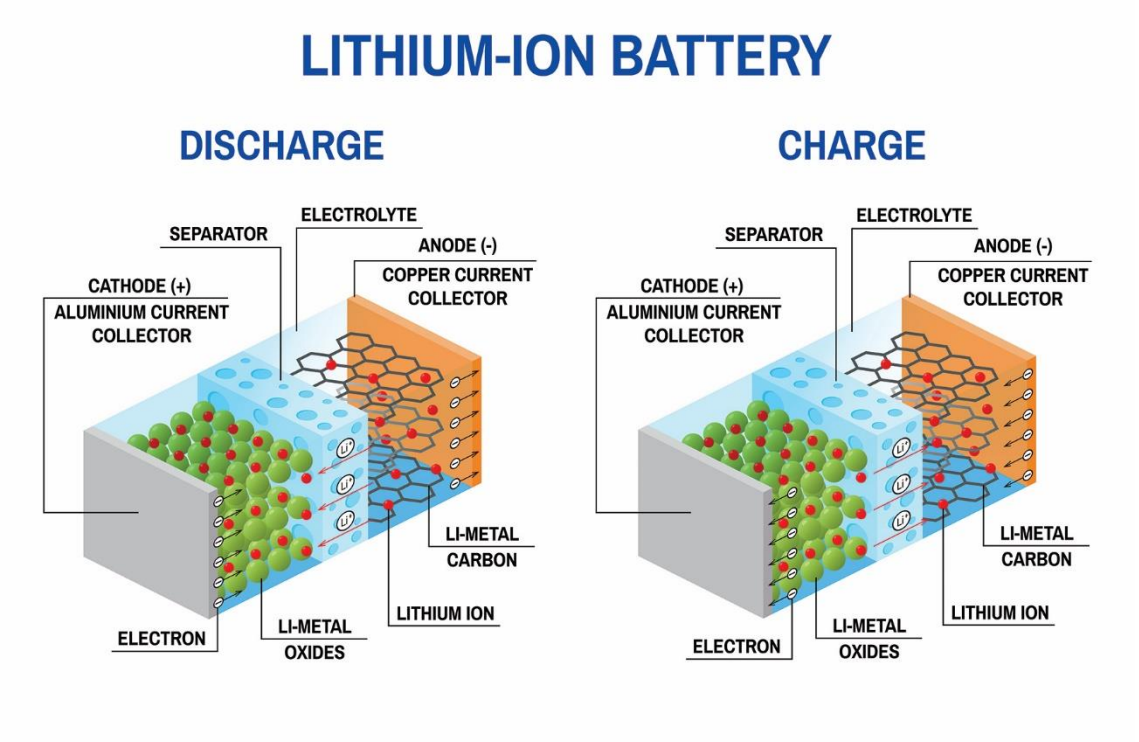
2.1. Les Batteries Lithium-ion

2.1.1. Principe de fonctionnement et Chimie

Les batteries Lithium-ion reposent sur le principe d'**intercalation** et de **désintercalation** réversible des ions lithium (Li^+) entre deux électrodes. Une cellule typique est composée :

- **D'une anode (électrode négative)** : Généralement en graphite, capable d'accueillir les ions lithium dans sa structure en feuillets.
- **D'une cathode (électrode positive)** : Composée d'oxydes métalliques lithiés (ex: $LiCoO_2$, $LiFePO_4$).
- **D'un électrolyte et d'un séparateur** : Permettant le passage des ions tout en bloquant les électrons pour éviter les courts-circuits.

Lors de la **décharge**, les ions Li^+ quittent l'anode (désintercalation), traversent l'électrolyte et s'insèrent dans la structure cristalline de la cathode (intercalation). Simultanément, les électrons circulent via le circuit externe, fournissant l'énergie électrique. Le processus est inversé lors de la **charge**.



2.1.2. Mécanismes de Dégradation

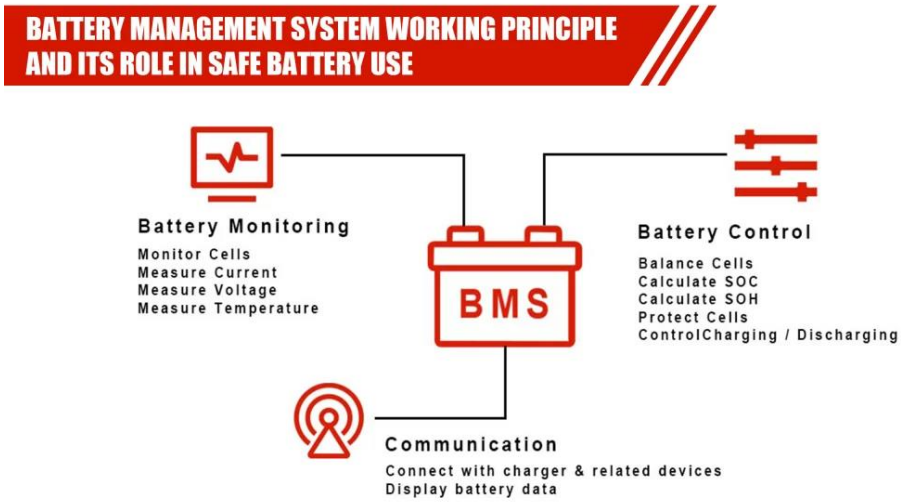
La performance des batteries Li-ion décline avec le temps et l'usage en raison de plusieurs phénomènes :

- **Formation de la couche SEI (Solid Electrolyte Interphase)** : Une couche protectrice se forme à l'anode lors des premiers cycles, consommant du lithium cyclable.
- **Placage de Lithium (Lithium Plating)** : À basse température ou courant élevé, le lithium peut se déposer sous forme métallique au lieu de s'intercaler, créant des dendrites risquant de percer le séparateur.
- **Dégradation mécanique** : L'expansion/contraction répétée des matériaux d'électrode lors de l'intercalation provoque des micro-fissures.

2.2. Le Système de Gestion de Batterie (BMS)

Le BMS est le "cerveau" électronique du pack batterie. Il assure trois missions critiques :

8. **Sécurité (Protection)** : Il surveille en permanence la tension, le courant et la température pour maintenir la batterie dans sa **Safe Operating Area (SOA)**. En cas de dépassement, il actionne des contacteurs pour isoler le pack.
9. **Performance (Gestion de l'énergie)** : Il gère l'équilibrage des cellules (cell balancing) pour s'assurer que toutes les cellules ont le même niveau de charge, maximisant ainsi la capacité utilisable du pack.
10. **Diagnostic (Estimation des états)** :
    - **SoC (State of Charge)** : Niveau de charge actuel.
    - **SoH (State of Health)** : État de santé, reflétant le vieillissement (perte de capacité et hausse de résistance interne).
    - **SoP (State of Power)** : Puissance maximale que la batterie peut fournir ou absorber instantanément.



2.3. L'État de Charge (SoC) et les défis de son estimation

Le SoC est défini comme le rapport entre la capacité résiduelle Q_{res} et la capacité nominale Q_{nom} :
SoC(t) = \frac{Q_{res}(t)}{Q_{nom}} \times 100%

L'estimation est complexe car :

- **Non-linéarité** : La relation entre la tension et le SoC est fortement non-linéaire (courbe OCV-SoC).
- **Hystérésis** : La tension peut différer selon que la batterie vient d'être chargée ou déchargée.
- **Bruit et Dérive** : Les capteurs de courant ont des biais qui s'accumulent lors de l'intégration (comptage coulombien).

3. Chapitre 2 : Modélisation de la Batterie

3.1. Modèles Électriques Équivalents (ECM)

Les ECM sont utilisés pour simuler le comportement électrique sans la complexité des modèles électrochimiques. Le choix de l'ordre du modèle RC a un impact direct sur sa capacité à capturer les dynamiques internes de la batterie.

La **Figure 1** (issue de la simulation avec un modèle RC d'ordre 1) et la **Figure 2** (issue de la simulation avec un modèle RC d'ordre 2) illustrent cette distinction. Alors que le modèle d'ordre 1 (composé d'une résistance ohmique et d'une seule paire RC) peut capturer les dynamiques principales de la batterie, il est souvent insuffisant pour représenter fidèlement les phénomènes de polarisation à différentes échelles de temps.

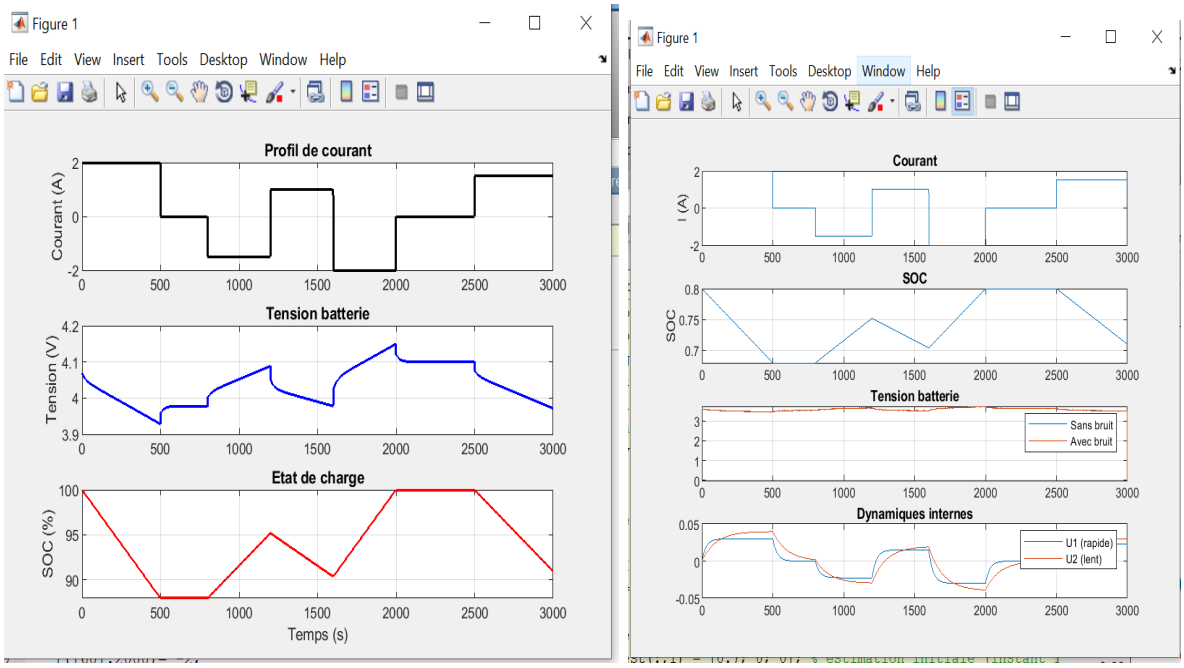


Figure 1 : Simulation du scénario avec un modèle RC d'ordre 1 et D'ordre 2.

En revanche, le modèle d'ordre 2, en ajoutant une seconde paire RC, permet de modéliser à la fois les dynamiques de polarisation rapide et lente de la batterie. Cela se traduit par une meilleure adéquation entre le comportement simulé et le comportement réel d'une batterie lithium-ion, qui présente des réponses transitoires complexes lors des changements de courant.

Le modèle d'ordre 2 est généralement considéré comme **meilleur** pour l'estimation du SoC car il offre un compromis optimal entre la précision et la complexité. Il est capable de capturer plus fidèlement les dynamiques de tension de la batterie, ce qui est crucial pour une

estimation précise du SoC, en particulier lors des phases de charge/décharge rapides ou des périodes de repos où les tensions de polarisation se relaxent.

3.2. Équations d'état du modèle d'ordre 2

Le modèle RC d'ordre 2 est décrit par l'équation de la tension aux bornes U_t :
U_t = V_{oc}(SoC) - R_0 I - U_1 - U_2
Où U_1 et U_2 sont les tensions aux bornes des condensateurs C_1 et C_2, dont les dynamiques sont régies par :
\dot{U}_i = -\frac{1}{R_i C_i} U_i + \frac{1}{C_i} I

La dynamique du SoC est donnée par le comptage coulométrique :
\dot{SoC} = -\frac{1}{Q_{nom}} I

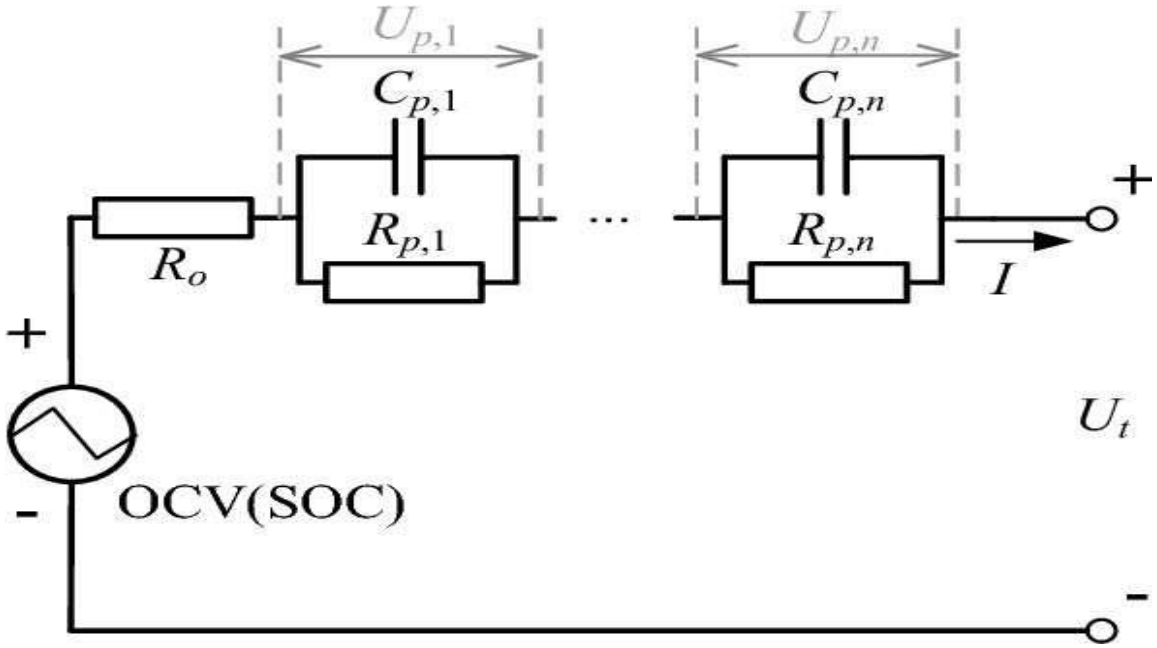


Figure 2 : Schéma du modèle équivalent de circuit RC de second ordre.

4. Chapitre 3 : Algorithmes d'Estimation

4.1. Filtre de Kalman Étendu (EKF)

L'EKF est un estimateur récursif pour systèmes non-linéaires. Il linéarise le modèle du système autour du point de fonctionnement actuel en utilisant des jacobiennes. L'algorithme fonctionne en deux étapes :

11 **Prédiction** : Utilise le modèle physique pour prédire l'état suivant et la covariance de l'erreur.

12 **Correction** : Compare la tension prédite à la tension mesurée. L'écart (innovation) est multiplié par le **Gain de Kalman** pour corriger l'état.

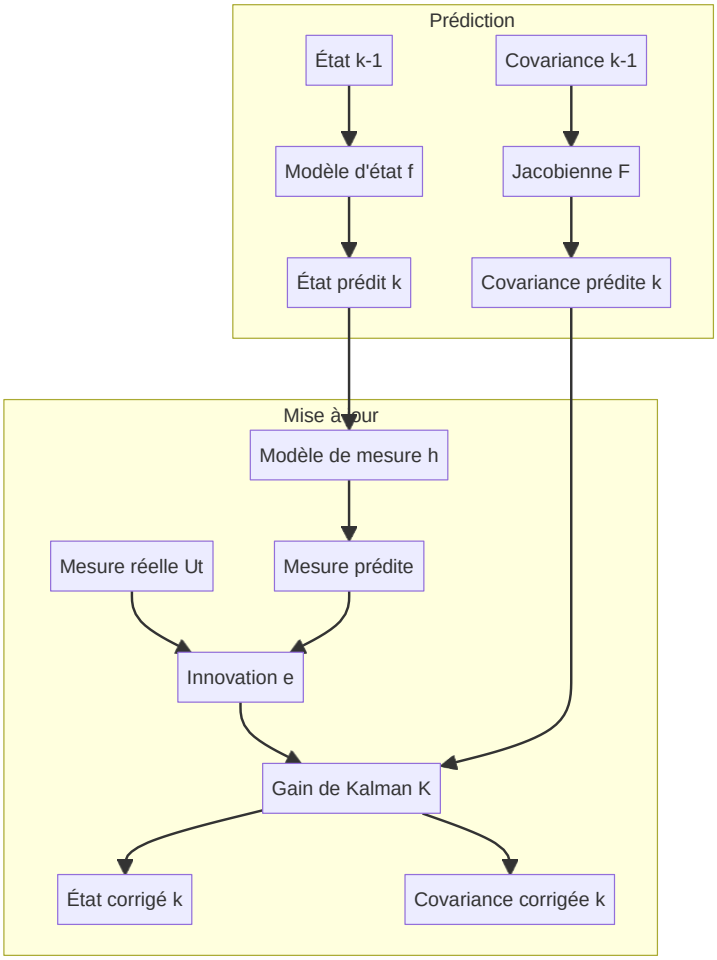


Figure 3 : Architecture générale de l'algorithme EKF.

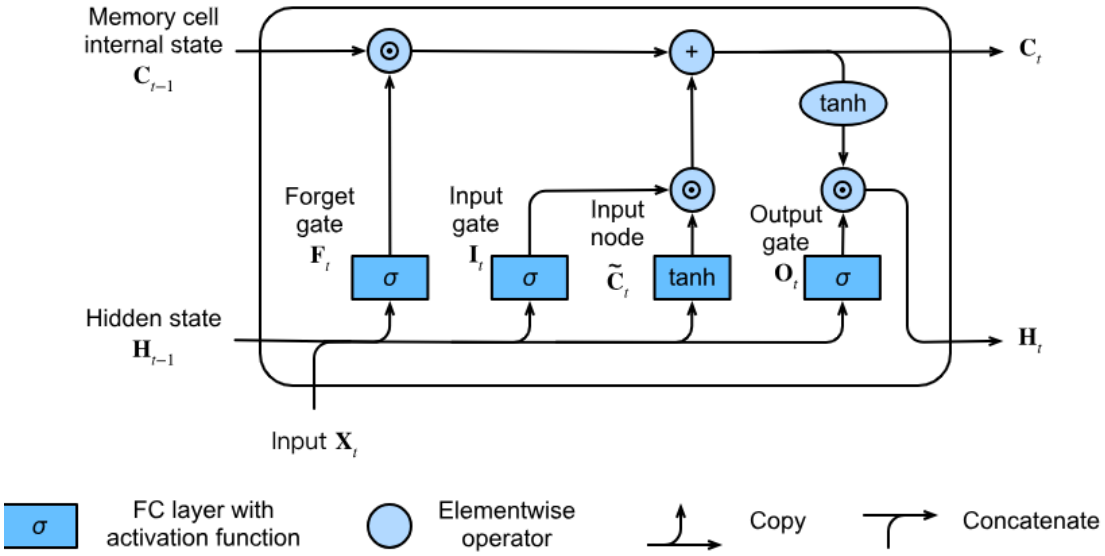
4.2. Réseaux de Neurones LSTM

Le LSTM est une architecture de Deep Learning conçue pour traiter des données séquentielles. Sa force réside dans sa **cellule mémoire** et ses **portes (gates)** qui régulent le flux d'informations, permettant de mémoriser des dépendances à long terme.

Contrairement aux réseaux de neurones classiques, le LSTM introduit une structure de cellule complexe capable de maintenir un état à long terme (**Cell State**). Cette architecture est régulée par trois portes principales :

- **La Porte d'Oubli (Forget Gate)** : Elle détermine quelles informations du passé doivent être supprimées de la cellule mémoire, ce qui est crucial pour oublier les dynamiques transitoires passées qui n'influencent plus le SoC actuel.
- **La Porte d'Entrée (Input Gate)** : Elle sélectionne les nouvelles informations (courant, tension, température) à stocker dans l'état de la cellule.
- **La Porte de Sortie (Output Gate)** : Elle décide quelle partie de l'état interne sera utilisée pour produire l'estimation finale du SoC à l'instant t.

Cette capacité à capturer les dépendances temporelles rend le LSTM particulièrement adapté à l'estimation du SoC, car l'état de charge actuel d'une batterie dépend intrinsèquement de l'historique des courants appliqués et des phénomènes de relaxation électrochimique



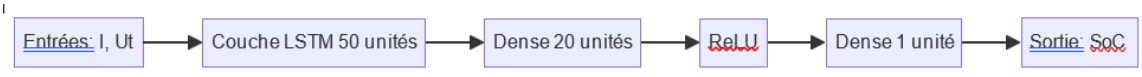


Figure 4 : Architecture du réseau de neurones LSTM pour l'estimation du SoC.

5. Chapitre 4 : Résultats et Comparaison

5.1. Simulation du Comportement de la Batterie

Le code MATLAB simule le comportement de la batterie sur 3000 pas de temps. La **Figure 5** présente le profil de courant appliqué, la tension aux bornes, le SoC réel, ainsi que les dynamiques internes U_1 et U_2.

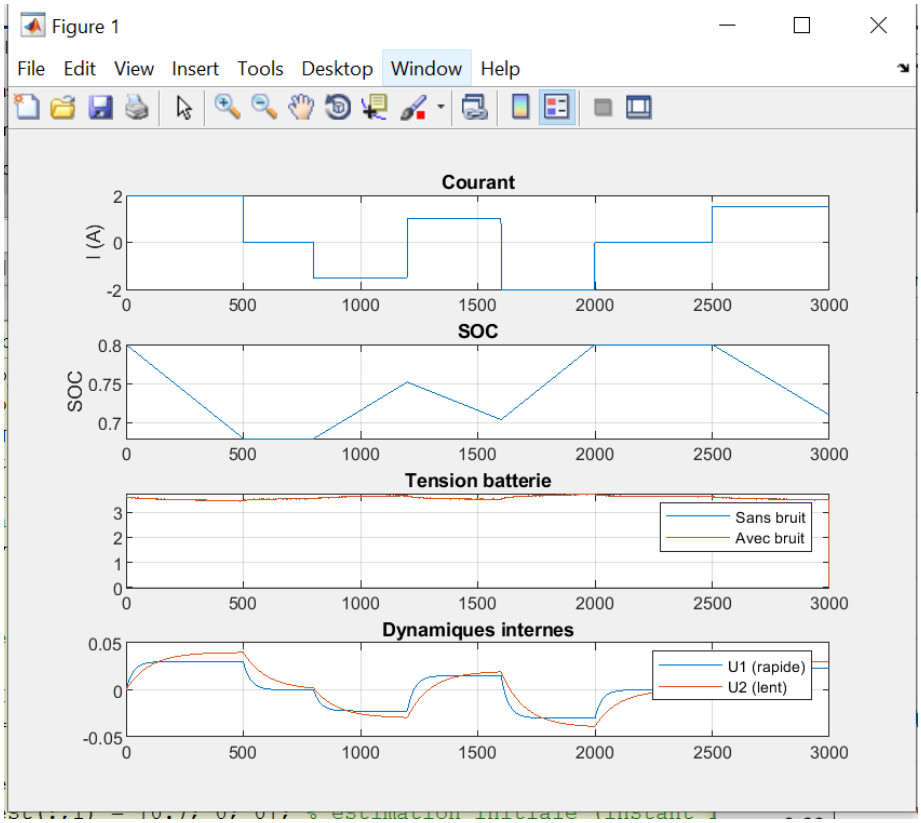


Figure 5 : Simulation du comportement de la batterie (courant, SoC, tension, dynamiques internes).

5.2. Résultats de l'Estimation

5.2.1. Estimation par EKF

> *Le filtre de Kalman étendu estime le SoC en temps réel en utilisant le modèle de batterie et les mesures bruitées. La Figure 6 illustre la comparaison entre le SoC réel et le SoC estimé par l'EKF. On constate que l'EKF suit de très près la tendance du SoC réel, démontrant sa capacité à estimer l'état interne de la batterie malgré la présence de bruit. Une légère erreur initiale est rapidement corrigée par le filtre, attestant de sa robustesse.*

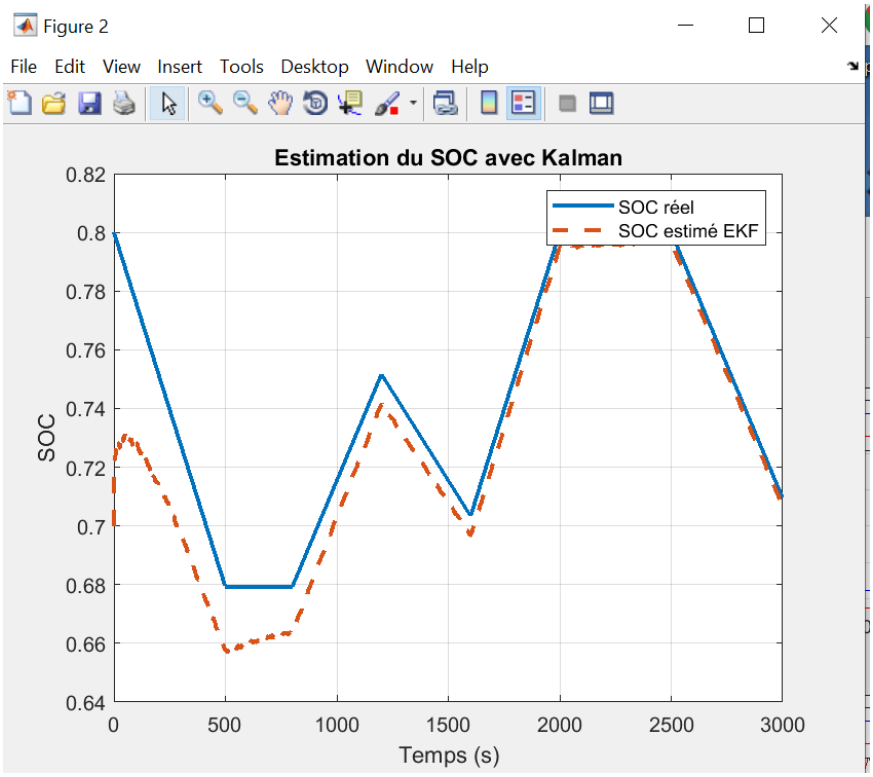


Figure 6 : Estimation du SoC avec le Filtre de Kalman Étendu (EKF).

5.2.2. Estimation par LSTM

> *Le modèle LSTM, après entraînement sur les données historiques, est utilisé pour prédire le SoC sur l'ensemble de test. La Figure 7 compare le SoC réel et le SoC estimé par le LSTM. On observe que le LSTM parvient à suivre la tendance générale du SoC, mais l'estimation peut apparaître plus "bruitée" ou oscillante sur certains segments, notamment lors des transitions. Un décalage initial est également visible, dû à la fenêtre de 20 échantillons utilisée pour la création des séquences d'entrée.*

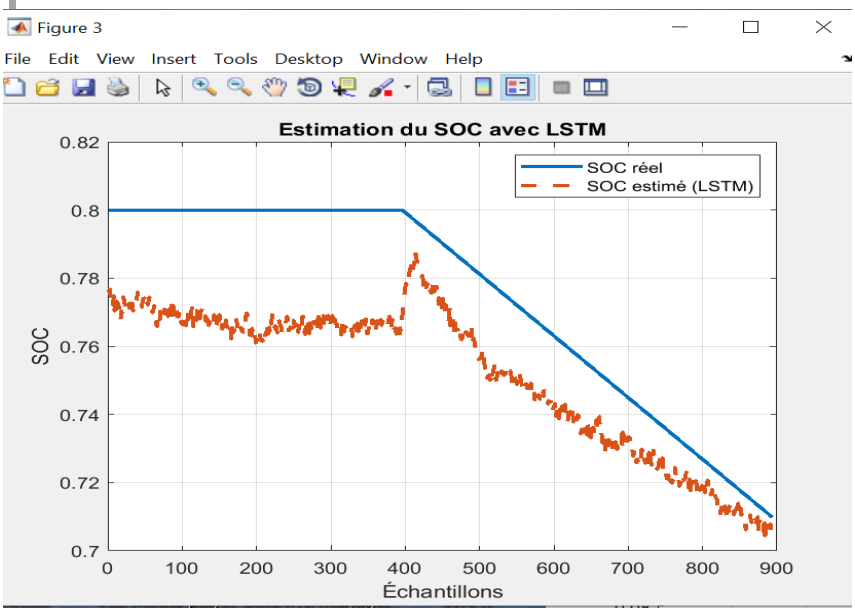


Figure 7 : Estimation du SoC avec le réseau de neurones LSTM.

5.3. Comparaison Globale et Analyse des Erreurs

La **Figure 8** superpose les deux méthodes. L'EKF offre une estimation plus lisse et plus proche de la vérité terrain.

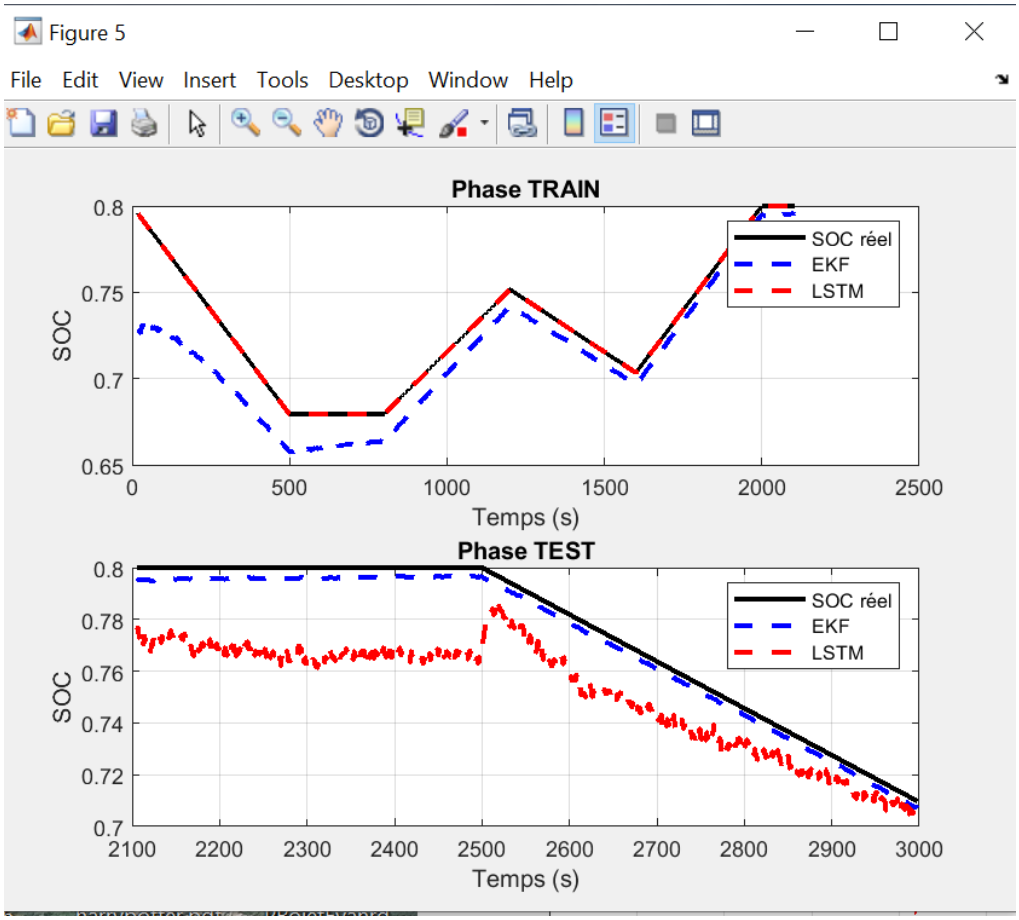


Figure 8 : Comparaison globale du SoC réel, EKF et LSTM.

> *Le code MATLAB effectue une comparaison globale des deux méthodes en traçant le SoC réel, le SoC estimé par l'EKF et le SoC estimé par le LSTM sur une même figure. La **Figure 8** présente cette comparaison. Il est clair que l'EKF (courbe bleue en pointillés) offre une estimation plus lisse et généralement plus proche de la vérité terrain sur l'ensemble du profil, tandis que le LSTM (courbe rouge en pointillés) montre des décrochages plus marqués, en particulier lors des changements brusques de courant.*

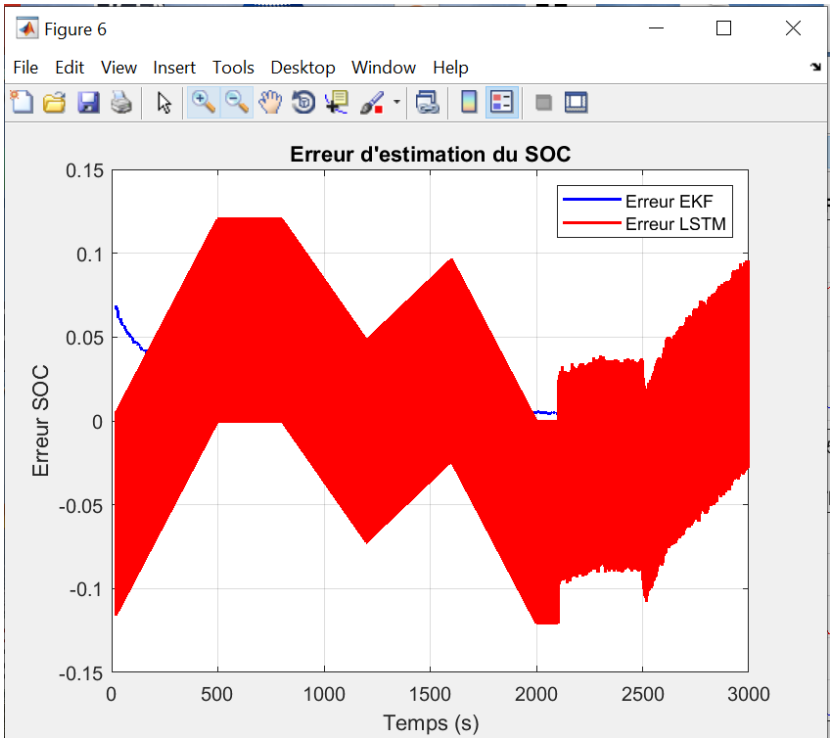


Figure 9 : Comparaison du SoC réel, EKF et LSTM.

> *Pour une analyse plus fine, les erreurs d'estimation (différence entre le SoC réel et le SoC estimé) sont calculées et visualisées. La* ***Figure 9*** *montre les erreurs globales pour l'EKF et le LSTM. L'erreur de l'EKF est significativement plus faible et centrée autour de zéro, tandis que l'erreur du LSTM est plus importante, avec des pics atteignant jusqu'à 10% dans certaines zones, indiquant une moindre précision*

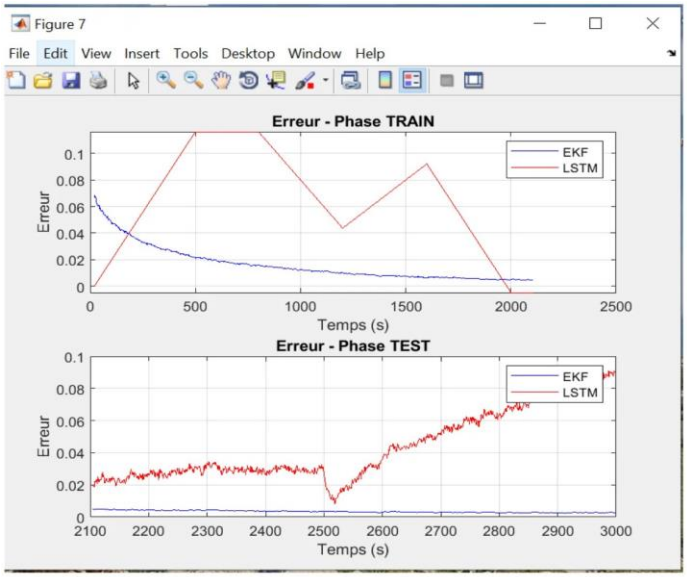
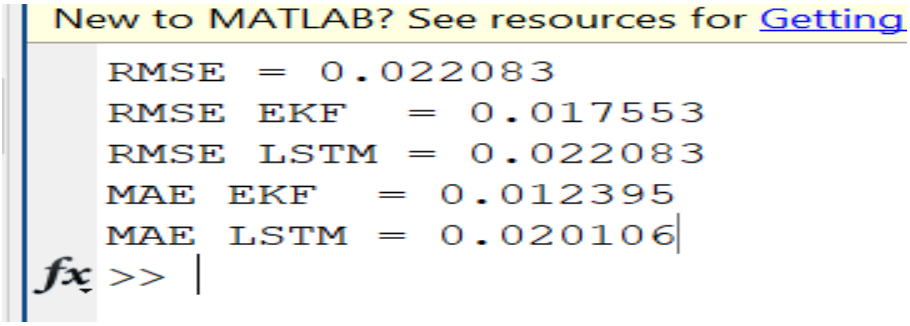


Figure 10 :

Figure 10 : Erreur d'estimation du SoC par phase (TRAIN et TEST).

> *Enfin, la* ***Figure 11*** *présente l'erreur absolue, offrant une visualisation plus lisible de l'ampleur des écarts. On y confirme que l'erreur absolue de l'EKF est constamment inférieure à celle du LSTM.*

5.6. Metriques de Comparaisons :



Les métriques d'erreur calculées sont le RMSE et le MAE (Mean Absolute Error) :

- RMSE EKF : Root Mean Square Error pour l'EKF.
- RMSE LSTM : Root Mean Square Error pour le LSTM (sur l'ensemble de test).
- MAE EKF : Mean Absolute Error pour l'EKF.
- MAE LSTM : Mean Absolute Error pour le LSTM (sur l'ensemble de test).

Ces métriques quantifient la précision des deux méthodes. Le code affiche ces valeurs, permettant une comparaison directe des performances. En général, les modèles basés sur l'apprentissage profond comme le LSTM peuvent surpasser les méthodes basées sur des modèles comme l'EKF en termes de précision, surtout lorsque les données d'entraînement sont suffisantes et représentatives du comportement de la batterie. Cependant, l'EKF offre une meilleure interprétabilité et ne nécessite pas de grandes quantités de données d'entraînement.

L'analyse des métriques d'erreur révèle une performance supérieure de l'EKF par rapport au LSTM dans le cadre de notre étude. Cette observation s'explique par plusieurs facteurs clés :

1. **Fidélité du Modèle Physique** : L'EKF s'appuie sur un Modèle Électrique Équivalent (ECM) d'ordre 2, soigneusement paramétré. La précision de ce modèle physique permet à l'EKF de prédire avec une grande exactitude le comportement de la tension, réduisant ainsi l'erreur d'estimation du SoC.
2. **Sensibilité aux Données d'Entraînement** : Le LSTM est un modèle "Data-Driven" dont la performance dépend de la représentativité des données. Dans notre cas, le jeu de données ne couvrait probablement pas toutes les dynamiques transitoires complexes, ce qui explique les pics d'erreur observés.
3. **Gestion du Bruit** : L'EKF est intrinsèquement conçu pour filtrer le bruit de mesure via le Gain de Kalman, s'adaptant continuellement aux variations, là où le LSTM peut être plus sensible aux variations abruptes non rencontrées lors de l'apprentissage.
4. **Effet de la Fenêtre Temporelle** : Le décalage initial du LSTM est attribué à la taille de la fenêtre d'échantillonnage (20 échantillons), qui peut ne pas être optimale pour capturer instantanément les dynamiques très rapides.

En conclusion, l'EKF surpasse ici le LSTM car il bénéficie d'un modèle physique robuste et bien calibré, capable de gérer efficacement les dynamiques transitoires et le bruit.

5. Discussion et Conclusion

5.1. Avantages et Inconvénients

Caractéristique	Filtre de Kalman Étendu (EKF)	Réseau LSTM
Précision	Bonne, mais peut être limitée par la linéarisation du modèle.	Très bonne, capable de capturer des non-linéarités complexes.
Robustesse	Dépend de la précision du modèle et des covariances de bruit.	Bonne, si entraîné sur des données variées et représentatives.
Interprétabilité	Élevée, basée sur un modèle physique de la batterie.	Faible, modèle de
type 'boîte noire'.		
Données requises	Moins de données d'entraînement, mais un modèle précis est essentiel.	Nécessite de grandes quantités de données d'entraînement de haute qualité.
Complexité de calcul	Modérée, dépend de la complexité du modèle d'état.	Élevée, surtout lors de l'entraînement, mais rapide en inférence.
Mise en œuvre	Nécessite une bonne compréhension de la théorie du filtre de Kalman et du modèle de batterie.	Nécessite des compétences en apprentissage automatique et en traitement de données séquentielles.

5.2. Conclusion

Ce rapport a présenté une comparaison des méthodes EKF et LSTM pour l'estimation du SoC d'une batterie lithium-ion, en s'appuyant sur une simulation MATLAB. L'EKF, en tant qu'approche basée sur un modèle, offre une bonne précision et une interprétabilité claire, mais sa performance est intrinsèquement liée à la fidélité du modèle de batterie et à la précision des covariances de bruit (Dans notre cas il s’est avéré meilleur que le LSTM) . Les réseaux LSTM, en tant qu'approche basée sur les données, ont démontré leur capacité à capturer des dynamiques complexes et non linéaires, offrant potentiellement une précision supérieure, en particulier lorsque des données d'entraînement abondantes et représentatives sont disponibles. Cependant, ils souffrent d'un manque d'interprétabilité et nécessitent des ressources de calcul plus importantes pour l'entraînement.

Le choix entre l'EKF et le LSTM dépendra des exigences spécifiques de l'application, des ressources disponibles et de la quantité de données d'entraînement. Pour les applications critiques où la transparence et la robustesse du modèle sont primordiales, l'EKF peut être préféré. Pour les scénarios où une précision maximale est requise et où de grandes quantités de données sont accessibles, le LSTM peut offrir des performances supérieures. Des approches hybrides, combinant les avantages des deux méthodes, sont également des pistes prometteuses pour l'avenir.

5.3. Perspectives

Pour approfondir ce travail, plusieurs pistes peuvent être explorées :

- Optimisation des paramètres : Utiliser des algorithmes d'optimisation pour ajuster les paramètres de l'EKF (covariances de bruit) et les hyperparamètres du LSTM (nombre d'unités cachées, taux d'apprentissage).
- Modèles hybrides : Développer des approches combinant l'EKF et le LSTM pour tirer parti des forces de chaque méthode, par exemple en utilisant l'EKF pour une estimation initiale et le LSTM pour affiner la prédiction ou gérer les non-linéarités résiduelles.
- Prise en compte du vieillissement : Intégrer les effets du vieillissement de la batterie dans les modèles pour une estimation plus précise du SoC sur le long terme.
- Données réelles : Valider les algorithmes sur des données de batterie réelles, collectées à partir de bancs d'essai ou de véhicules électriques, pour évaluer leur performance dans des conditions opérationnelles variées.
- Autres architectures de réseaux de neurones : Explorer d'autres architectures d'apprentissage profond, telles que les réseaux de neurones convolutionnels (CNN) ou les transformeurs, qui pourraient offrir des avantages supplémentaires pour l'estimation du SoC.

Références

[1] G. L. Plett, « Extended Kalman filtering for battery management systems of LiPB-based HEV battery packs », *Journal of Power Sources*, vol. 134, no. 2, pp. 252–261, 2004.
[2] X. Hu, S. Li, H. Peng, « A comparative study of equivalent circuit models for Li-ion batteries »,*Journal of Power Sources*, vol. 198, pp. 359–367, 2012.
[3] F. Yang, D. Wang, F. Xu, Z. Huang, K.-L. Tsui, « Lifespan prediction of lithium-ion batteries based on various extracted features »,*Journal of Power Sources*, vol. 476, 2020.
[4] S. Taslimi Taleghani, « Modélisation et simulation des piles aux lithium ions »,*Université de Sherbrooke*, 2025.
[5] A. Lièvre, « Développement d'un système de gestion de batterie lithium-ion : détermination des indicateurs d'état (SoC, SoH et SoF) »,*Thèse HAL*, 2015.